Predicción de Abandono de Clientes en una Empresa de Telecomunicaciones

Pre-entrega – Proyecto Final Integrador

Diplomado en Ciencia de Datos y Análisis Avanzado

Autor: Mateo Revelchione

Fecha: 6 de septiembre de 2026

1. Resumen ejecutivo

Este proyecto aborda el abandono de clientes (churn) en una empresa de telecomunicaciones. El problema afecta directamente al equipo de retención y a la gerencia comercial, que hoy no cuentan con un criterio sistemático para priorizar a qué clientes contactar antes de que cancelen el servicio. Se busca construir un modelo que estime la probabilidad de baja de cada cliente a partir de su perfil de contratación, servicios contratados y comportamiento de pago, de manera de anticipar la acción comercial. El KPI de negocio principal es la tasa de abandono mensual (actualmente del 26,5% en la muestra disponible) y, de forma secundaria, la eficiencia de las campañas de retención medida como la proporción de clientes que efectivamente iban a darse de baja dentro del grupo que el equipo decide contactar.

2. Definición del problema y caso de negocio

Objetivo medible: clasificar a cada cliente activo según su probabilidad de darse de baja en el corto plazo, con un desempeño de al menos ROC AUC = 0,80 en validación, de forma que el equipo de retención pueda ordenar a los clientes de mayor a menor riesgo y concentrar sus recursos en el segmento superior.

Hipótesis de trabajo: el abandono no se explica igual para todos los clientes. En un análisis exploratorio previo sobre este mismo dataset (realizado en el Módulo 5 de la cursada) se observó que el riesgo de baja es considerablemente mayor en clientes con contrato mes a mes, con poca antigüedad, con internet por fibra óptica, que pagan con débito automático por cheque electrónico (Electronic check) y que no tienen contratados servicios adicionales como soporte técnico o seguridad online. La hipótesis de partida es que estas variables contractuales y de servicios adicionales van a tener más poder predictivo que los datos puramente demográficos (género, presencia de pareja o hijos a cargo).

Restricciones conocidas: se trabaja con una muestra estática de clientes (una foto en un momento dado), no con datos longitudinales, por lo que el modelo puede estimar probabilidad de baja pero no el momento exacto en que ocurriría. El dataset es una base pública utilizada con fines educativos, no los datos productivos reales de una empresa, por lo que las conclusiones deben tomarse como una aproximación razonable y no como una medición exacta del negocio. Tampoco se cuenta con información de costos de campaña ni con el valor de vida (LTV) real de cada cliente, por lo que el impacto económico se estima de forma aproximada a partir del cargo mensual facturado.

Valor esperado: si el equipo de retención pudiera actuar de forma dirigida sobre el segmento de mayor riesgo identificado por el modelo (en vez de contactar clientes al

azar o de forma reactiva) y lograra revertir aunque sea una fracción de esas bajas, el impacto se traduce directamente en los ingresos mensuales recurrentes que se dejarían de perder. Con una tasa de abandono del 26,5% sobre la base analizada, incluso una mejora moderada en la tasa de retención de los clientes de mayor riesgo representa un volumen de ingresos no menor para la empresa.

3. Relevamiento de fuentes de datos

Se utiliza el dataset de clientes de telecomunicaciones provisto durante la cursada (archivos train.csv y test.csv, derivados del dataset público "Telco Customer Churn"), que funciona como proxy razonable de los datos de CRM de una empresa real de telecomunicaciones. Es una base pública, sin restricciones de uso para fines educativos, y no contiene datos personales identificables más allá de un identificador de cliente anonimizado (customerID).

Tamaño: train.csv contiene 5.634 clientes y 21 columnas (incluye la variable objetivo Churn); test.csv contiene 1.409 clientes y 20 columnas (sin Churn, reservado para la predicción final). En conjunto suman 7.043 clientes, en línea con el dataset público de referencia.

Diccionario mínimo de variables principales

Variable	Tipo	Descripción
customerID	Texto (ID)	Identificador único de cliente. Se descarta como predictor.
gender	Categórica	Género del cliente (Male / Female).
SeniorCitizen	Binaria (0/1)	Indica si el cliente es adulto mayor.
tenure	Numérica	Antigüedad del cliente en meses (rango observado: 0 a 72).
Contract	Categórica	Tipo de contrato: Month-to-month, One year o Two year.
InternetService	Categórica	Tipo de servicio de internet: DSL, Fiber optic o No.
PaymentMethod	Categórica	Método de pago (4 categorías, incluye Electronic check).
MonthlyCharges	Numérica (USD)	Cargo mensual actual facturado al cliente.
TotalCharges	Numérica (USD)	Cargo acumulado histórico del cliente.
Churn	Binaria (No/Yes)	Variable objetivo: si el cliente se dio de baja o no.

Nulos, outliers y calidad de datos

Chequeo	Resultado
Valores nulos (train, 21 columnas)	No se detectaron valores nulos en ninguna columna.

Chequeo	Resultado
Valores nulos (test, 20 columnas)	No se detectaron valores nulos en ninguna columna.
Registros duplicados (customerID)	No se encontraron customerID duplicados en train.
Balance de clases (Churn)	No = 4.139 (73,5%) / Yes = 1.495 (26,5%). Desbalance moderado.
Rango de tenure	0 a 72 meses, sin valores negativos ni fuera de rango físico esperable.
Rango de MonthlyCharges	Aproximadamente entre 18 y 120 USD, sin valores negativos.
Distribución de TotalCharges	Cola larga hacia la derecha, coherente con clientes de mayor antigüedad; sin valores negativos.

Decisiones de limpieza ya tomadas: se descarta customerID como variable predictora (es un identificador, no aporta señal). Se recodifica la variable objetivo Churn a formato binario (0/1) para poder calcular métricas de clasificación.

Decisiones pendientes: aplicar un criterio formal de detección de outliers (rango intercuartílico) sobre tenure, MonthlyCharges y TotalCharges para decidir si corresponde algún tratamiento, aunque a priori no se esperan valores erróneos dado que los rangos observados son físicamente razonables. También queda pendiente definir si se aplica alguna técnica de balanceo de clases (por ejemplo, class_weight o SMOTE) dado el desbalance 73/27, y validar si conviene agrupar categorías poco frecuentes dentro de las variables de servicios adicionales antes de la codificación final.

4. Plan de modelado y validación

Métricas a reportar: ROC AUC como métrica principal (robusta frente al desbalance de clases), acompañada de precisión, recall y F1 de la clase Churn = Yes, y la matriz de confusión. Se suma una métrica orientada al negocio: el recall obtenido dentro del 20% de clientes con mayor riesgo estimado, que refleja mejor la capacidad operativa real del equipo de retención para actuar sobre una porción acotada de la base.

Esquema de validación: partición estratificada 80/20 (holdout) sobre train.csv, complementada con validación cruzada estratificada de 5 folds sobre el conjunto de entrenamiento para reportar media y desvío estándar de cada métrica. Este es el mismo esquema aplicado en la iteración exploratoria del Módulo 5.

Umbral de éxito: se fija como piso un ROC AUC de al menos 0,80 en validación. Este umbral es alcanzable: en la iteración exploratoria previa, un modelo simple de Regresión Logística ya obtuvo ROC AUC = 0,848 en validación (0,845 en cross-validation de 5 folds) sobre este mismo dataset, por encima de kNN y Naive Bayes. Ese resultado se toma como baseline reproducible a igualar o superar con el modelo final.

Benchmark de negocio: el modelo debe superar claramente dos referencias simples: (a) un contacto aleatorio de clientes, cuya tasa de acierto esperada equivale a la tasa base de churn (26,5%), y (b) una regla simple del tipo "contactar a todos los clientes con contrato mes a mes". El objetivo es lograr un lift de al menos 2x respecto del contacto aleatorio dentro del segmento de mayor riesgo.

Modelos a explorar: además de los ya evaluados como baseline (Regresión Logística, kNN y Naive Bayes), para la entrega final se plantea incorporar modelos de ensamble basados en árboles (Random Forest y Gradient Boosting), que suelen capturar mejor las interacciones entre variables categóricas sin requerir tanto trabajo manual de preprocesamiento.

5. Riesgos, limitaciones y próximos pasos

- El dataset es una foto estática de clientes, no un histórico longitudinal: el modelo puede estimar probabilidad de baja, pero no el momento exacto en que ocurriría.

- Al ser una base pública derivada y no los datos productivos reales de la empresa, los resultados deben tomarse como una aproximación razonable al problema, no como una medición exacta de impacto de negocio.

- El desbalance de clases (73/27) puede afectar el recall real del modelo si no se ajusta el umbral de decisión considerando el costo relativo de contactar de más a un cliente frente al de no contactar a uno que efectivamente se iba a dar de baja.

- Próximo paso inmediato: entrenar y comparar los modelos de ensamble propuestos, definir el umbral de decisión en función de un costo estimado de campaña de retención, y traducir la salida del modelo en una recomendación operativa concreta para el equipo de retención.