Priorización de clientes para campañas de retención

Predicción de abandono (churn) en una empresa de telecomunicaciones

Proyecto Final Integrador · Diplomado en Ciencia de Datos y Análisis Avanzado (UTN.BA) · Unidad 9

Equipo N.º 41 · Aguilar, Damian · Revelchione, Mateo · 10/10/2026

El problema: un cupo limitado de contactos

¿A quién conviene llamar primero para evitar bajas?

20 %

de la cartera puede contactar el equipo de retención por campaña

26,5 %

de los clientes de la muestra figura como baja. Es la proporción de la muestra, no una tasa mensual

Hoy la lista de contactos se arma **sin un criterio sistemático**.

Cada llamada a alguien que no se iba es una oferta desperdiciada; cada baja que queda afuera es ingreso perdido.

El producto analítico es un **ranking de riesgo**: ordenar a los clientes y usar el cupo primero con los de mayor riesgo.

Audiencia: gerencia comercial y equipo de retención.

Cómo medimos el éxito

Metas fijadas en la pre-entrega, antes de entrenar ningún modelo

Recall @ 20 %

% de las bajas que quedan dentro del cupo.

Meta: ≥ 40 % (el doble que el azar)

Precision @ 20 %

% de los contactados que realmente se iban: eficiencia de la campaña

ROC-AUC

Calidad técnica del ranking.

Meta: ≥ 0,80

Benchmarks: contacto al azar (captura ~20 % de las bajas) y una regla de negocio simple: contratos mes a mes de menor antigüedad primero.

Por qué no accuracy: predecir siempre "no se va" logra 73,5 % de accuracy y no prioriza a nadie.

Datos: fuente oficial, trazable y de buena calidad

Fuente

Telco Customer Churn (IBM)

7.043 clientes · 19 variables

Apache License 2.0

Sin datos personales reales

Trazabilidad

train/test del curso = partición exacta del archivo oficial

Baseline de la pre-entrega reproducido: ROC-AUC 0,848

Test del curso (1.409 clientes) como holdout nunca visto

Calidad

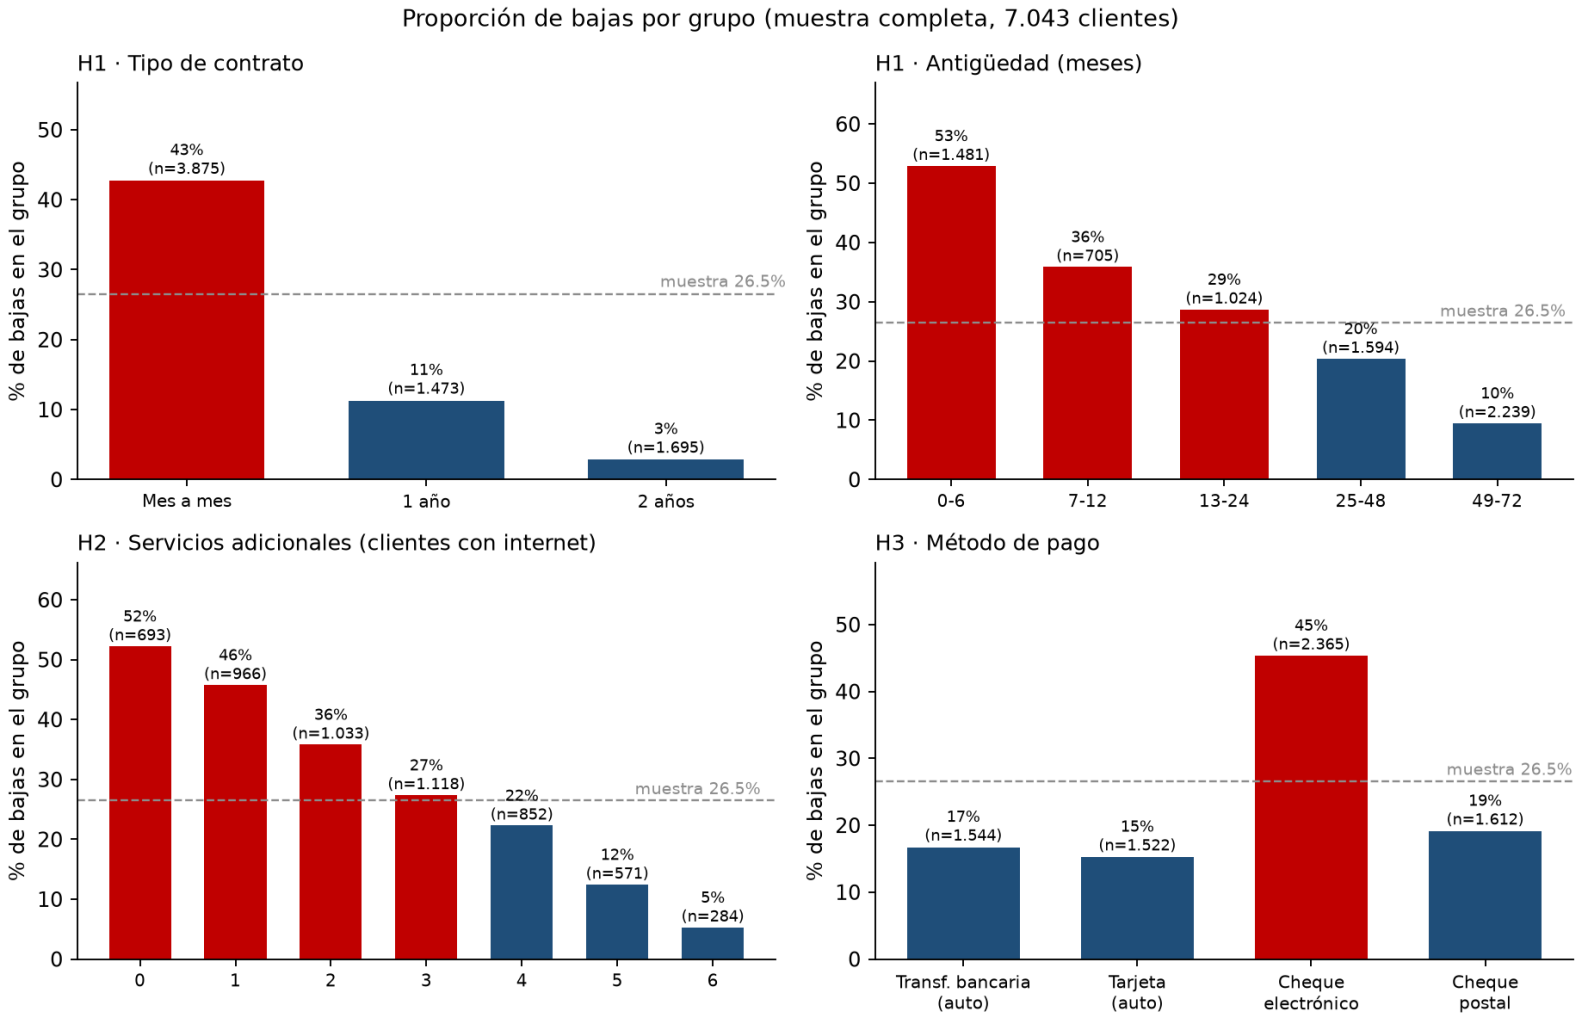
0 nulos · 0 outliers (IQR)

11 blancos en TotalCharges: clientes nuevos → 0

22 perfiles repetidos: clientes distintos, se conservan

Qué se asocia a las bajas

Proporción de bajas por grupo (7.043 clientes)



Contrato mes a mes: 43 % de bajas vs 3 % en 2 años

Primeros 6 meses: 53 %

Sin servicios adicionales (con internet): 52 % vs 5 % con los seis

Cheque electrónico: 45 % · **fibra óptica:** 42 %

Género: no discrimina (27 % vs 26 %)

Cinco algoritmos y una regla definida antes de mirar el test

Validación cruzada de 5 folds sobre 5.634 clientes · metodología CRISP-DM

Modelo	ROC-AUC	Recall @ 20 %	Empatado
Regresión logística	**0,846**	**50,6 %**	**Sí**
XGBoost	0,844	50,7 %	Sí
Random Forest	0,844	50,2 %	Sí
Naive Bayes	0,820	48,8 %	Sí
kNN (k=15)	0,819	47,6 %	No

Regla de selección:

1. ROC-AUC ≥ 0,80

2. Empate: a menos de un desvío del mejor Recall @ 20 %

3. Si empata la logística, se elige la logística

Resultado: empatan 4 modelos → **regresión logística**: más simple, interpretable y entrena en 0,05 s.

Con el 20 % de los contactos se captura la mitad de las bajas

Test: 1.409 clientes que no participaron de ninguna decisión

49,7 %

de las bajas capturadas (IC 95 %: 46-55 %)

66,0 %

de los contactados realmente se iba

2,5x

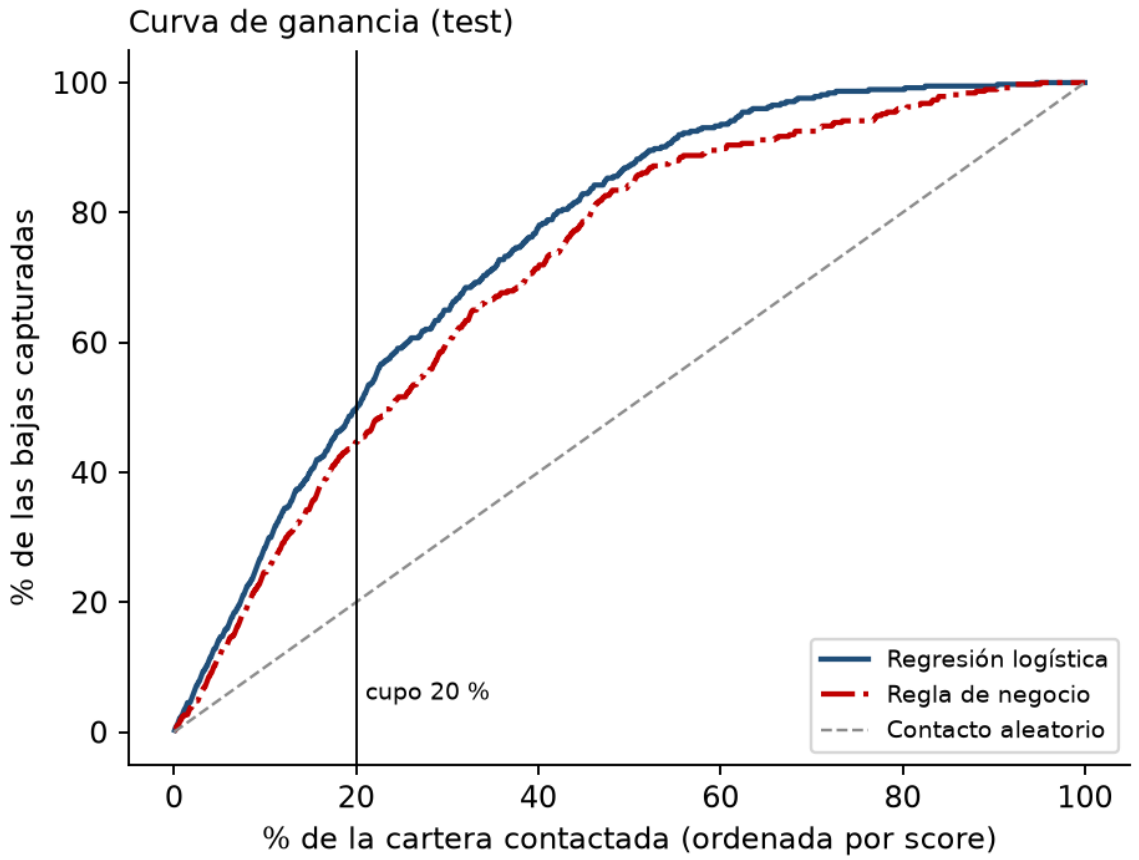
mejor que contactar al azar

54 %

del ingreso mensual en riesgo (regla: 38 %)

Regla de negocio: 44,7 %. El modelo suma **+5,1 p.p.** de bajas y prioriza a quienes pagan más.

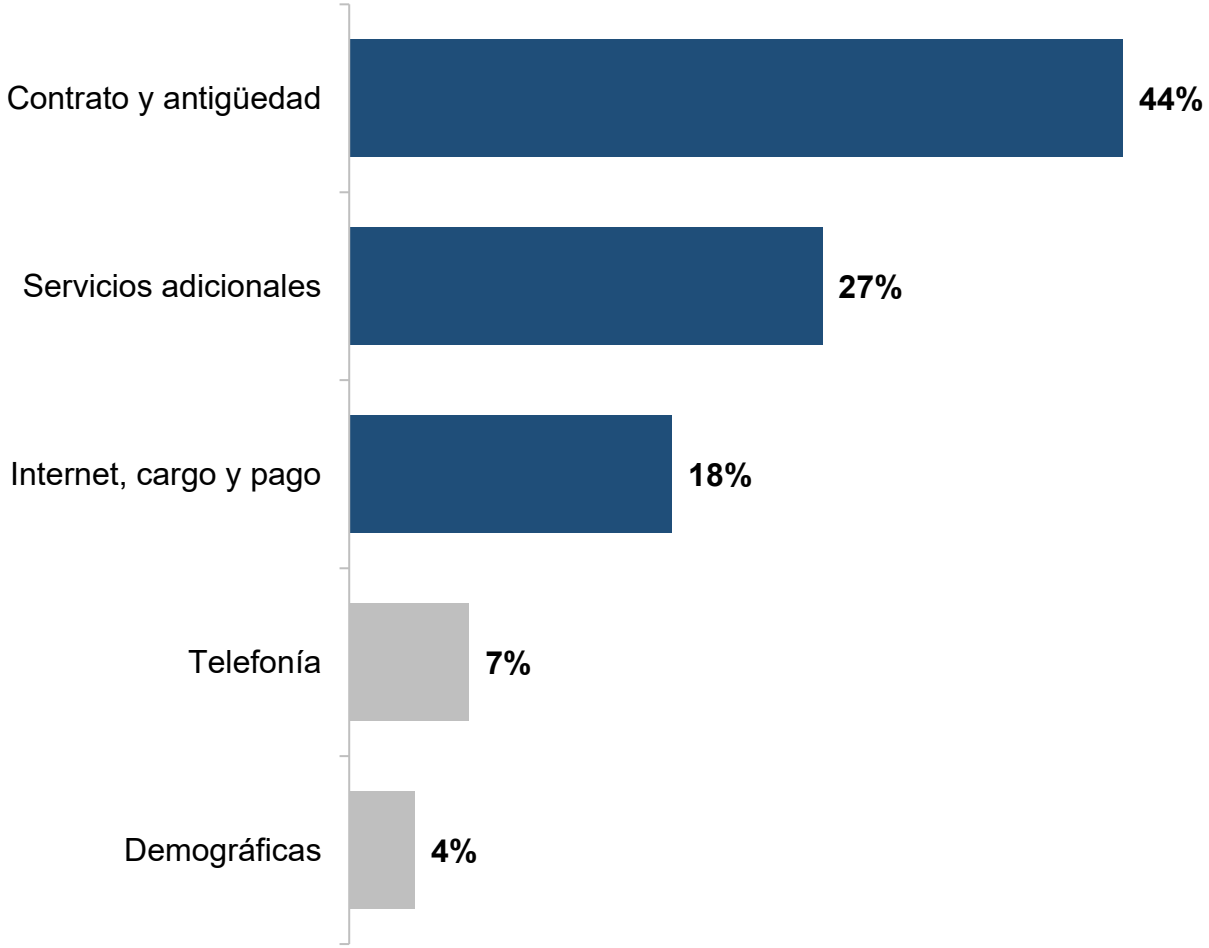
Metas cumplidas: Recall @ 20 % ≥ 40 % y ROC-AUC 0,842.



Curva de ganancia: % de bajas capturadas según % de la cartera contactada

¿Por qué el modelo prioriza a un cliente?

Peso de cada bloque de variables en las decisiones del modelo (SHAP)



Empujan hacia la baja: contrato mes a mes, pocos meses de antigüedad, fibra óptica, sin seguridad online ni soporte técnico.

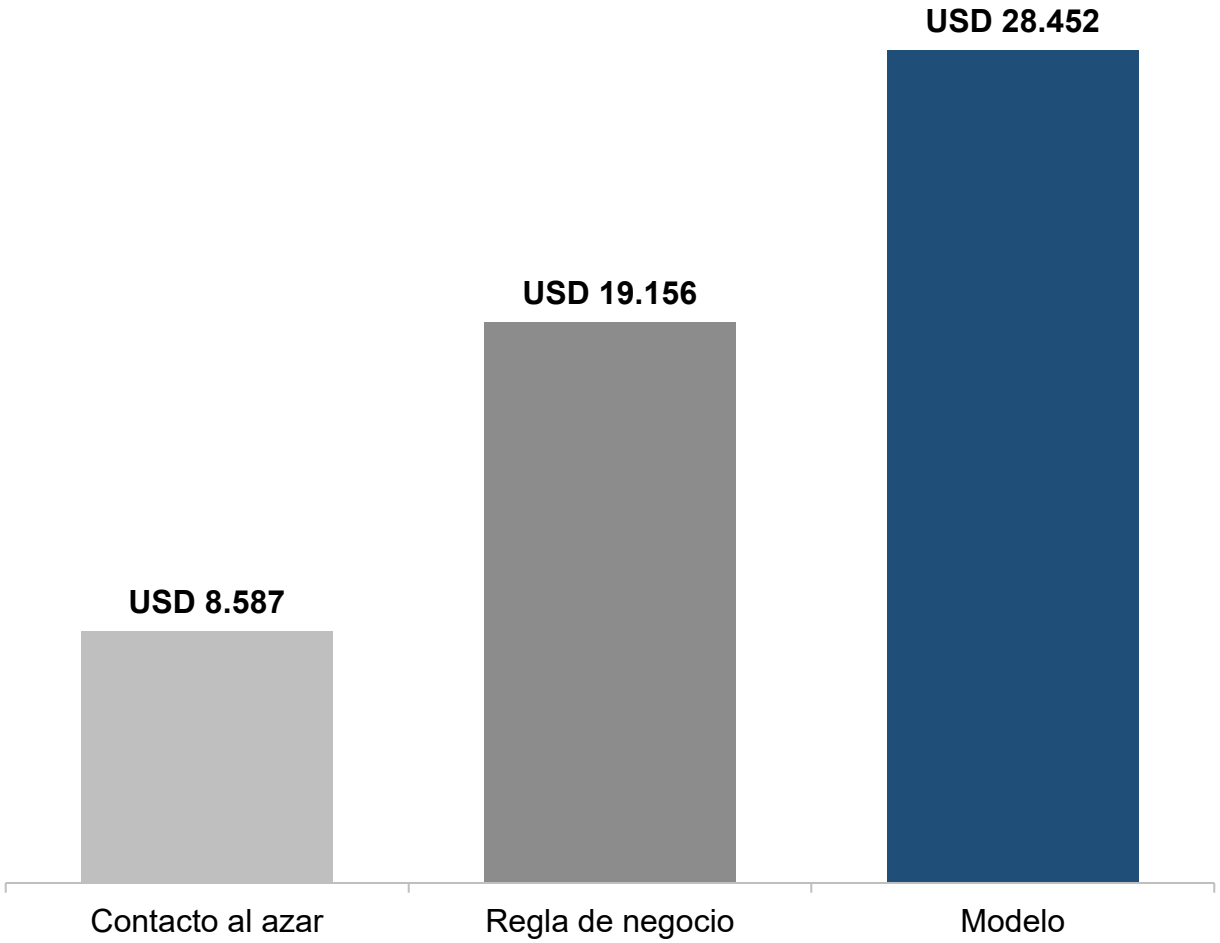
Las variables demográficas casi no aportan (4 %): se pueden quitar sin perder desempeño.

Ejemplo real: cliente con 4 meses, fibra y contrato mes a mes → score 65,9 % (se dio de baja). Acción sugerida: ofrecer contrato anual y soporte técnico.

SHAP explica cómo decide el modelo; no prueba causalidad.

Valor para el negocio

Beneficio neto por campaña cada 1.000 clientes · escenario paramétrico, no son costos reales



+USD 9.296 frente a la regla actual y **+USD 19.866** frente al azar, por campaña cada 1.000 clientes.

El modelo no pierde plata con solo **2,4 % de retención** de las bajas contactadas.

Supuestos: USD 15 por contacto, 25 % de retención, 12 meses de ingreso. Con 10 % de retención y USD 25 por contacto sigue en positivo.

El valor real depende de la proporción de bajas en la cartera activa: se mide en un piloto.

Ética y riesgos

Auditoría por grupos (test)

Adultos mayores: **38 %** seleccionados vs 17 % del resto.

Clientes con hijos a cargo: el modelo captura **27 %** de sus bajas vs 55 %.

Género: equilibrado.

Sin las 4 variables demográficas el desempeño es el mismo (49,2 % vs 49,7 %) → **recomendamos esa versión** y monitorear la selección por grupo: la diferencia por edad persiste por variables proxy.

Riesgos y mitigaciones

Sin fechas en los datos → validar con cortes temporales y reentrenar.

Datos de muestra (telco ficticia) → piloto A/B antes de escalar.

Efecto de la propia campaña → 5-10 % de la cartera como grupo de control.

Ofertas a quien no se iba (34 % del cupo) → incentivos escalonados.

Privacidad con datos reales → Ley 25.326: minimización y acceso restringido.

Recomendación: piloto antes de desplegar

1

Datos reales

Reconstruir el dataset desde el CRM con fecha de corte y ventana de observación de 30/90 días.

2

Piloto A/B

2-3 campañas: modelo sin variables demográficas vs regla actual, mismo presupuesto y grupo de control.

3

Medir

Bajas evitadas, costo por cliente retenido, Recall @ 20 % y selección por grupo.

4

Escalar

Solo si el piloto confirma el beneficio. Probar XGBoost y sumar datos de uso y reclamos.

Código y resultados: github.com/mateorevelchione/DCDyAA-Unidad9-Grupo41-Churn-Telco